



复杂缺失模式下基于自适应截断Schatten 范数的交通数据补全方法

答辩人：邓浩彭

答辩时间：2025年3月1日

目录

CONTENTS

- 一、 研究背景
- 二、 研究内容
- 三、 结果展示
- 四、 学术成果

01


研究背景

现实问题：数据缺失对交通系统的多重影响



交通管理规划失误01

世界银行报告指出，精准数据可将城市交通规划效率提升**15%-20%**；而数据缺失可能导致基建决策偏离实际需求，造成资源浪费。



增加交通安全隐患02

欧盟委员会数据显示，交通安全数据每缺失**10%**，事故分析和预防效率便会下降约**25%**，严重阻碍安全隐患的识别与治理。



限制智能交通系统03

麦肯锡全球研究表明，每缺失**1%**关键交通数据，智能交通系统效率将降低**2%-3%**，影响信号灯、导航系统、自动驾驶的运行。

政策导向：交通强国+数字交通的重大需求

交通运输部文件

交规划发〔2021〕102号

交通运输部关于印发 《数字交通“十四五”发展规划》的通知

各省、自治区、直辖市、新疆生产建设兵团交通运输厅(局、委)：
现将《数字交通“十四五”发展规划》印发给你们，请认真贯彻执行。



(此件公开发布)

高质量交通数据支持


01

《数字交通“十四五”发展规划》指出，**高质量交通数据**是智能交通系统（ITS）运行的**核心基石**。本作品响应《规划》中提升交通数据**完整性与可靠性**的需求，为ITS的**高效运行**提供有力支持。


02

数据驱动的交通管理

《交通强国建设纲要》强调数据资源推动交通高质量发展。本作品紧扣《纲要》提出的**大数据+交通、人工智能+交通**目标，通过精准的交通数据补全技术，赋能数据驱动的交通管理与智能服务优化。



研究现状：当前主要研究方向



时序分析方法

发展出 ST-DCGAN、SBU-LSTM、LCR 等模型，挖掘交通数据时间依赖特性，适用单路段或固定时间序列的数据补全。

局限：忽略交通数据的空间关联性，限制其在多维场景中的应用。

空间分析方法

发展出 GAN 路网重构法、RDGCNI、MagiNet 等模型，基于交通网络空间关联性，通过拓扑关系与特征传播补全数据。

局限：过于依赖节点关系，未能捕捉交通数据的时间动态特性。

时空分析方法

发展出 HaLRTC、TNN、TSpN 等模型，综合时间和空间特性，重建交通数据整体结构，适配复杂缺失场景，补全精度较高。

局限：模型复杂、效率低下，对超参数调优和数据同构性较为依赖。

The slide features a dark blue header bar at the top. On the left side, there is a decorative graphic consisting of two concentric circles with a light blue gradient, centered around the number '02'. A thin grey line with a dot at its end curves around the bottom of the circles.

02

研究内容

研究框架与思路



问题构建：交通数据的时空关联性


选取两个具有代表性的交通数据集，以阐述交通数据的**时空关联性**。

中国广州城市路网车速数据集：建模为三维张量 $\mathcal{T}_G \in \mathbb{R}^{214 \times 61 \times 144}$ ，对应 214 个路段、61 天、144 个时间窗口。

英国伯明翰停车场占用率数据集：建模为三维张量 $\mathcal{T}_B \in \mathbb{R}^{14 \times 73 \times 18}$ ，对应 14 个停车场、73 天、18 个时间窗口。


工作日早晚高峰的车速明显下降，反映出通勤所致的交通拥堵。

Heatmap of Traffic Speed for Road Section




周末与节假日的车速整体较高，表示此时交通压力较小。

中午时段停车场占用率较高，符合人们日常出行规律。



交通数据具有 **时空关联性**，邻近传感器的记录通常呈现相似模式，特定时间窗口的数据在相近日期间也表现出相似趋势。这种时空相似性正是数据补全的基础。**张量** 作为多维数据结构的自然延伸，相较于传统的向量和矩阵，能够 **更全面地** 捕捉交通流数据中的时空关联性。



基本原理：利用时空关联性补全数据




交通数据补全和图像修复的核心思想是相似的：**利用数据的低秩性**，从观测部分中推断缺失部分。图像修复主要通过**低秩矩阵补全（LRMC）** 算法实现。

我们将LRMC**升维**为**低秩张量补全（LRTC）**，捕捉数据的**多维关联性**，从而实现更精准的数据补全。

基本思路是运用**奇异值分解**将交通数据张量分解为低秩结构，利用其**低秩性（时空关联性）**补全数据。




创新点1：复杂缺失模式生成框架



(a) EM Scenario

元素缺失 (EM) 致因:
因传感器短暂故障或瞬时传输错误, 导致数据点呈现随机散布型丢失。

生成方法:
通过生成随机张量标记缺失值, 并基于预设缺失率对元素进行随机删除。




(b) FM Scenario


纤维缺失 (FM) 致因:
由传感器长期故障或周期性系统中断引发, 表现为沿某一维度的连续数据丢失。

生成方法:
沿随机选定维度, 从随机起点开始连续删除固定长度的数据段, 直至满足目标缺失率。

在实际应用中, 基于历史数据 **参数估计** EM-FM的占比, 即可 **精准还原** 真实交通数据中 **多样化的缺失特性**。



(c) MM (0.2EM, 0.8FM) Scenario



(d) MM (0.4EM, 0.6FM) Scenario

混合缺失 (MM) 致因:
多重因素协同作用, 形成元素缺失与纤维缺失交织的复杂场景。


生成方法:
融合EM与FM的生成逻辑, 调整二者比例模拟真实的缺失场景。

创新点2：自适应截断Schatten范数

LRTC 模型

LRTC模型利用数据的**低秩性质**，通过**最小化张量秩**来推断缺失值。由于直接最小化秩是**NP难**问题，通常采用**核范数**作为**凸松弛**近似来解决。如图所示，传统LRTC模型将原始张量沿三个模式展开为三个矩阵，然后通过矩阵**奇异值分解**（SVD）计算核范数。

$$\underbrace{\min_{\mathcal{X}} \text{rank}(\mathcal{X})}_{\text{秩最小化}} \longrightarrow \underbrace{\|\mathcal{X}\|_* = \sum_{k=1}^N \|\mathcal{X}(k)\|_*}_{\text{核范数}} \longrightarrow \underbrace{\min_{\mathcal{X}} \sum_{k=1}^N \|\mathcal{X}(k)\|_*}_{\text{核范数最小化}}$$




Schatten 范数

为提高模型**精度与灵活性**，我们以Schatten范数代替传统的核范数松弛。Schatten范数在核范数基础上加入了两个新的参数：**模式权重** α_k ，**参数** p 。 α_k 衡量展开模型 k 对低秩性质的贡献， p 控制Schatten范数对奇异值的敏感度。

$$\underbrace{\|\mathcal{X}\|_* = \sum_{k=1}^N \|\mathcal{X}(k)\|_*}_{\text{核范数}} \xrightarrow{\alpha_k, p} \underbrace{\|\mathcal{X}\|_{S_p} = \left(\sum_{k=1}^N \alpha_k \|\mathcal{X}(k)\|_{S_p}^p \right)^{1/p}}_{\text{Schatten范数}}$$

当 $0 < p < 1$ 时，Schatten 范数呈**非凸特性**，能够更有效地惩罚小奇异值，从而实现更高的稀疏性和更紧凑的低秩结构。如图所示，随着 p 值趋近 0，Schatten 范数的曲线愈接近张量秩，非凸性增强，**求解精度**显著提高。



创新点2：自适应截断Schatten范数

截断Schatten范数

奇异值衡量不同特征维度的重要性：较大的奇异值表示**主要趋势和周期性成分**；而较小的奇异值则对应**短期、偶发或无规律的波动**。为减少较小奇异值的干扰，我们在Schatten范数中加入了截断操作：

$$\underbrace{\|\mathcal{X}\|_{\theta, S_p}}_{\text{截断Schatten范数}} = \left(\sum_{k=1}^N \alpha_k \|\mathcal{X}_{(k)}\|_{\theta, S_p}^p \right)^{\frac{1}{p}} = \left(\sum_{k=1}^N \alpha_k \left(\sum_{i=r_k+1}^{\min\{I_k, \prod_{i \neq k} I_i\}} \sigma_i^p(\mathcal{X}_{(k)}) \right) \right)^{\frac{1}{p}}$$

$$r_k = \underbrace{\left\lceil \theta \cdot \min\{I_k, \prod_{i \neq k} I_i\} \right\rceil}_{\text{第 } k \text{ 个矩阵的截断阈值}}$$


最终的优化目标函数

在 LRTC 中应用截断 Schatten 范数后，优化问题变为：

$$\min_{\mathcal{X}} \|\mathcal{X}\|_{\theta, S_p}^p = \min_{\mathcal{X}} \sum_{k=1}^N \alpha_k \|\mathcal{X}_{(k)}\|_{\theta, S_p}^p$$

参数 p 、截断率 θ 和模式权重 α_k 的选择**至关重要**。在不同的数据集、缺失模式和迭代阶段中，其**最佳取值不同**。对此，我们采用**自适应调参**策略提高模型的适应性和整体性能。

如下图所示，通过截断阈值**过滤**较小的奇异值，**减少**其噪声影响，进一步**提高**数据修复精度。



创新点3：集成Nesterov动量的Adan算法

自适应
参数更新

01

Nesterov 动量

核心机制：在更新参数前“**预看**”下一步位置的梯度变化，提前调整方向，**减少优化过程中的震荡**。

主要优势：提升梯度优化的方向性和效率，提高参数调整的精准性。


02

Adan 算法



核心机制：综合梯度、梯度差分与动量，自适应调整学习率，从而高效**逃离非凸优化的局部最优区域**。

主要优势：加速收敛，减少噪声干扰，提升模型泛化能力和优化效率。

如右图所示，五个前沿优化器在两个深度学习模型训练中，Adan 算法的损失值最低。



(a) Training and test curves on ResNet-50.



(b) Training and test curves on ViT-S.

创新点3：集成Nesterov动量的Adan算法

1. 参数动态寻优 (p 和 θ)

集成 Nesterov 动量的 Adan 算法:

$$m^{(t)} = \beta_1 m^{(t-1)} + (1 - \beta_1) g^{(t)}$$
$$v^{(t)} = \beta_2 v^{(t-1)} + (1 - \beta_2) (g^{(t)})^2$$
$$\hat{m}^{(t)} = \frac{m^{(t)}}{1 - \beta_1^t}, \quad \hat{v}^{(t)} = \frac{v^{(t)}}{1 - \beta_2^t}$$

分别计算一阶、二阶动量以及偏差校正。

参数更新规则:

$$p_{t+1} = \text{clip} \left(p_t - \eta \frac{\hat{m}^{(t)}}{\sqrt{\hat{v}^{(t)} + \epsilon}}, 0.1, 1 \right)$$
$$\theta_{t+1} = \text{clip} \left(\theta_t + \eta \frac{\hat{m}^{(t)}}{\sqrt{\hat{v}^{(t)} + \epsilon}}, 0, 1 \right)$$

其中, p 控制非凸性, θ 控制截断阈值。


2. 模式权重平滑更新 (α_k)

权重计算: 基于模式重要性 (Frobenius 范数):

$$\hat{\alpha}_k = \frac{\|M_k\|_F}{\sum_{j=1}^N \|M_j\|_F} + \lambda \left(\frac{1}{N} - \frac{\|M_k\|_F}{\sum_{j=1}^N \|M_j\|_F} \right)$$
$$\alpha_k^{(t+1)} = (1 - \gamma) \alpha_k^{(t)} + \gamma \hat{\alpha}_k \quad (\text{归一化后生效})$$

3. 创新点总结:

- 动态寻优: 根据梯度自适应调整, 避免手动调参。
- 鲁棒性: 通过动量机制平滑梯度震荡, 加速收敛。
- 灵活性: 权重 α_k 反映数据内在模式关联性。





自适应更新机制的核心目标在于 **动态调整** Schatten范数参数 p 、截断率 θ 以及模式权重 α_k ，从而 **平衡精度与效率**，迭代流程如右上图示。

求解算法

求解算法

为了高效解决带截断的张量 Schatten 范数最小化引入的非凸优化问题，采用**交替方向乘子法（ADMM）**与**截断广义软阈值化（TGST）**相结合的方法（ADMM-TGST）。此方法将复杂的优化问题分解为一系列易于求解的子问题进行交替优化，并结合**自适应参数更新机制**，逐步逼近最优解。




03

结果展示

实验结果：收敛效率

我们对各模型在**两个实测数据集**（广州G与西雅图S）和**三种混合缺失模式**下进行了收敛效率分析。结果表明，MAPE（平均绝对百分比误差）和 RMSE（均方根误差）在最初的 **5** 次迭代中迅速下降，并在 **30** 次迭代稳定在可接受水平。如下表所示，LRTC-ATSN 的效率**超越所有**基线模型 **20%** 以上。



Datasets	Missing Pattern	TMR	BPMF	BGCP	HaLRTC	LRTC-TNN	LRTC-TSpN	LRTC-ATSN
G	EM 0.1 FM 0.1	19.60%	91.691	57.914	30.564	24.129	20.912	15.915
	EM 0.3 FM 0.3	48.62%	207.556	131.088	69.185	54.622	47.337	37.654
	EM 0.5 FM 0.5	69.75%	291.021	183.803	97.007	76.584	66.373	53.378
	EM 0.7 FM 0.7	85.00%	383.564	242.251	127.855	100.938	87.479	64.401
	EM 0.9 FM 0.9	95.85%	417.859	263.911	139.286	109.963	95.301	70.047
S	EM 0.1 FM 0.1	18.52%	127.204	85.339	42.401	33.475	29.011	22.079
	EM 0.3 FM 0.3	47.91%	272.064	171.827	90.687	71.595	62.049	49.356
	EM 0.5 FM 0.5	69.37%	389.622	246.077	129.874	102.532	88.861	71.463
	EM 0.7 FM 0.7	84.80%	520.298	328.617	173.433	136.921	118.665	87.359
	EM 0.9 FM 0.9	95.78%	592.801	374.536	197.697	156.312	135.258	99.373

Best results are marked in bold font.


实验结果：补全精度

下表给出**两个数据集**和**五种混合缺失模式**下各模型的补全精度。结果包括在 0.1、0.3、0.5、0.7和 0.9 的比例下的 EM-FM 组合。所使用的评估指标是 MAPE / RMSE。结果表明，LRTC-ATSN 的补全精度始终优于其他模型。即便在缺失率高达 95.85% 的极端条件下，与最优基线模型相比，该模型仍实现了 **10.6%** 的 MAPE 和 **6.1%** 的 RMSE 降低。


Datasets	Missing Pattern	TMR	BPMF	BGCP	HaLRTC	LRTC-TNN	LRTC-TSpN	LRTC-ATSN
G	EM 0.1 FM 0.1	19.60%	0.106/4.412	0.104/4.321	0.088/3.561	0.073/3.160	0.073/3.132	0.072/3.097
	EM 0.3 FM 0.3	48.62%	0.108/4.491	0.104/4.318	0.098/3.929	0.082/3.530	0.081/3.423	0.078/3.360
	EM 0.5 FM 0.5	69.75%	0.112/4.665	0.103/4.316	0.109/4.301	0.089/3.849	0.087/3.689	0.087/3.676
	EM 0.7 FM 0.7	85.00%	0.119/4.951	0.104/4.320	0.123/4.800	0.098/4.195	0.093/ 3.943	0.093/3.947
	EM 0.9 FM 0.9	95.85%	0.139/5.675	0.107/4.473	0.819/33.808	0.111/4.627	0.105/4.409	0.105/4.355
S	EM 0.1 FM 0.1	18.52%	0.098/5.526	0.100/5.613	0.071/3.952	0.052/3.329	0.052/3.318	0.050/3.233
	EM 0.3 FM 0.3	47.91%	0.099/5.616	0.101/5.615	0.082/4.440	0.060/3.761	0.058/3.583	0.057/3.582
	EM 0.5 FM 0.5	69.37%	0.103/5.818	0.099/5.555	0.098/5.078	0.072/4.359	0.065/3.966	0.066/4.028
	EM 0.7 FM 0.7	84.80%	0.114/6.327	0.101/5.640	0.121/5.959	0.090/5.274	0.077/ 4.531	0.076/4.590
	EM 0.9 FM 0.9	95.78%	0.169/8.529	0.105/5.900	0.200/9.356	0.360/23.742	0.113/6.135	0.101/5.758

Best results are marked in bold font.


实验结果：插值可视化




(a) LRTC-ATSN, G , EM: 0.2, FM: 0.3



(b) LRTC-TSpN, G , EM: 0.2, FM: 0.3



(c) LRTC-ATSN, S , EM: 0.5, FM: 0.6



(d) LRTC-TSpN, S , EM: 0.5, FM: 0.6

为更直观地体现 LRTC-ATSN 的补全精度，我们与最优基线模型 LRTC-TSpN 进行了插值可视化对比

在总缺失约为41.28%的 G 数据集中（图a），LRTC-ATSN 实现了 **28.3%** 的残差面积减少 (1463.12 vs. 2040.98)

在总缺失约为 72.21% 的 S 数据集中（图c），LRTC-ATSN 实现了 **36.1%** 的残差面积减少 (320.33 vs. 501.29)

研究贡献总结

01

针对缺失场景单一瓶颈:

构建了混合缺失模式生成器, 模拟真实交通场景中元素缺失、纤维缺失及其复合形态, 为模型评估提供了标准化基准。

02

针对补全精度不足瓶颈:

设计了一种基于自适应截断 Schatten 范数的低秩张量补全模型 (LRTC-ATSN), 有效提高了复杂缺失场景下的补全精度。

03

针对求解效率不高瓶颈:

采用集成 Nesterov 动量的 Adan 优化算法, 显著加速了模型收敛, 使其在处理大规模交通数据张量时兼顾精度和效率。

04

学术成果

Adaptive Truncated Schatten Norm for Traffic Data Imputation with Complex Missing Patterns

本作品已被第 25 届 COTA 国际交通科技年会（**CICTP 2025**）正式接受，并计划于会上进行报告展示。论文将由美国土木工程师学会（**ASCE**）出版，提交至**El Compendex**检索。CICTP 由美国交通运输研究会（**TRB**）特别支持，属于交通科技领域的一流会议。

Adaptive Truncated Schatten Norm for Traffic Data Imputation with Complex Missing Patterns

Haopeng Deng, Fucheng Zheng, Kaixiang Ma, Xinhai Xia*

School of Intelligent Transportation and Engineering (School of Future Transportation), Guangzhou Maritime University, Guangzhou, 510725, China; E-Mail: xiaxinhai@126.com

ABSTRACT

Accurate traffic data imputation is essential for Intelligent Transportation Systems (ITS), particularly under complex missing patterns. This study presents the Adaptive and Truncated Schatten Norm Low-Rank Tensor Completion (LRTC-ATSN) model, which employs the flexible Schatten norm for low-rank approximation and introduces an adaptive truncation mechanism to suppress noise and retain core features. To address non-convex optimization, the model integrates the Adan algorithm with Nesterov momentum, achieving equilibrium between computational efficiency and recovery precision through dynamic parameter tuning. To evaluate performance, a framework was designed to simulate diverse real-world traffic scenarios with mixed missing patterns. Extensive experiments on datasets from Guangzhou and Seattle demonstrate that LRTC-ATSN outperforms existing methods, yielding 10.6% lower MAPE and 6.1% lower RMSE relative to the best baseline model. Even with 95.85% data loss, the model maintains high reliability. These results underscore LRTC-ATSN's potential for enhancing ITS data robustness and applications across domains like finance and healthcare.

keywords: Traffic Data Imputation, Low-Rank Tensor Completion, Missing Data Patterns, Adaptive Update, Non-Convex Optimization, Truncated Schatten Norm

INTRODUCTION

Intelligent Transportation Systems (ITS) are integral to modern urban traffic management, ensuring both efficiency and safety through optimizing traffic flow, route planning, and signal control. However, as L. Yang et al. (2024) highlight, missing traffic data—especially during peak hours or on critical road segments—can impair system performance, leading to inaccuracies in traffic regulation and suboptimal signal control. These challenges make traffic data imputation a vital research priority.

Traffic data imputation methods are typically divided into three groups: temporal, spatial, and spatiotemporal. Temporal methods, such as the Laplacian Convolution Representation (LCR) model (X. Chen, Cheng, et al., 2024), focus on capturing time dependencies for imputation tasks. Spatial methods, like the RDGCNI model (Y. Chen et al., 2022), analyze traffic state propagation across stations utilizing dynamic graph

challenge for data recovery, requiring methods that handle large-scale restoration. To generate MM, we define the $EMR + FMR$, where EMR and FMR represent the edge missing and fiber missing, respectively. By adjusting the combination of missing scenarios can be easily simulated.

(b) FM Scenario

(d) MM (0.4EM, 0.6FM) Scenario

ations under different missing patterns with missing rates

ange of traffic data reconstruction under complex missing patterns using the Adaptive and Truncated Schatten Norm Low-Rank Tensor Completion (LRTC-ATSN). By combining Schatten norms with a truncation operation, the model effectively penalizes small singular values to achieve sparsity. Furthermore, the Adaptive Nesterov momentum algorithm dynamically adjusts model parameters based on dataset characteristics and accuracy in data imputation.

s to minimize the tensor rank, formulated as $\min_{\mathcal{X}} \text{rank}(\mathcal{X})$. However, this is typically approximated using nuclear norm relaxation, where the nuclear norm is defined as the sum of the singular values of the unfolded matrix $X_{(k)}$. To conserve entries, an observation mask tensor $\mathcal{P}_\Omega$ is applied, where Ω is the set of observed positions, expressed as:

accuracy and flexibility of LRTC, we introduce the Schatten p -norm as a traditional nuclear norm relaxation. For an N -th order tensor $\mathcal{X}$, the Schatten norm is defined as (Gao et al., 2020):

$$\|\mathcal{X}\|_{S_p} = \left(\sum_{k=1}^N \alpha_k \|\mathcal{X}_{(k)}\|_{S_p}^p \right)^{\frac{1}{p}}, \quad (2)$$

mode weights, representing the contribution of mode k to the overall norm. The weights satisfy $\alpha_k \geq 0$ and $\sum_{k=1}^N \alpha_k = 1$. The parameter p controls the Schatten norm's sensitivity to singular values. When $p=1$, it reduces to the nuclear norm; when $p=2$, it becomes the Frobenius norm. For $0 < p < 1$, it becomes non-convex, effectively penalizing large singular values and promoting sparsity. Figure 3 shows the Schatten norm closely approximates the tensor rank at the cost of higher computational complexity.

Figure 3: Schatten Norm with Singular Values for $0 < p < 1$

Figure 4: Schatten Norm with Singular Values for $0 < p < 1$

Figure 5: Schatten Norm with Singular Values for $0 < p < 1$

The 25th COTA International Conference of Transportation Professionals (CICTP2025)

Transportation · Artificial Intelligence (AI) · Energy

July 22-25, 2025

South China University of Technology, Guangzhou, China

Adaptive Truncated Schatten Norm for Traffic Data Imputation with Complex Missing Patterns

Hide abstract

Accurate traffic data imputation is vital for Intelligent Transportation Systems (ITS), particularly under complex missing conditions. This study introduces the Adaptive and Truncated Schatten Norm Low-Rank Tensor Completion (LRTC-ATSN) model, developed to address these imputation challenges with high precision. The model integrates non-convex Schatten norms with an self-adjusting truncation mechanism, effectively balancing sparsity control and recovery accuracy. An adaptive update strategy, incorporating the Adan algorithm with Nesterov momentum, dynamically adjusts parameters for optimal performance. Extensive experiments on real-world traffic datasets from Guangzhou and Seattle demonstrate that LRTC-ATSN outperforms existing models across various missing rates, maintaining strong accuracy even at a 95.78% missing rate. In scenarios with mixed missing patterns, LRTC-ATSN shows improvements of 10.6% in MAPE and 6.1% in RMSE compared to state-of-the-art models. These results underscore the LRTC-ATSN model's potential for enhancing data reliability in ITS and other applications requiring robust data completion.

Submission files:

Adaptive Truncated Schatten Norm for Traffic Data Imputation with Complex Missing Patterns 1110.pdf

Supplementary Files:

Paper 736_Xinhai Xia.pdf
Parper 736_CTA_Xinhai Xia.pdf

Supplementary Material:

Edit Supplementary Material
Email: Email Meta-Reviewer
Email Senior Meta-Reviewer

Accepted for Presentation and Publication Reviews

项目支持

本研究得到了以下项目与资金的支持：

- **广东省教育厅重点科研平台和项目：**

“大数据驱动下的城市交通流状态数据修复及运行平衡状态识别理论与方法研究”

“多Agent强化学习范式下的城市路网动态用户均衡路径选择博弈建模研究”

(NO.2022ZDZX1021、2024ZDZX1033)

- **广东省科技创新战略专项资金资助项目：**

“基于合作博弈的路网配流机制对优化城市交通效率的可行性研究” (NO.PDJH2024A289)

- **广州市教育局科研项目：**

“城市智能网联与人工驾驶混合流环境下随机交通拥堵演化机理研究” (NO.2024312023)

An aerial photograph of a complex highway interchange with multiple lanes and overpasses. A solid blue horizontal band is superimposed across the center of the image, serving as a background for the text.

敬请批评指正